

机器学习在心血管疾病诊断中的研究进展

赵梦蝶¹ 孙九爱²

摘 要 当前医生对心血管疾病的诊断主要依赖对患者心血管影像的分析,同时,医生还需要考虑患者的各项生理健康指标、既往病史、生活环境等信息,该方法存在效率低和成本高等问题。因此,人们试图利用机器学习方法辅助心血管疾病的诊断。本文首先总结了机器学习在冠状动脉计算机断层扫描、超声心动图、心电图等多种心血管影像处理中的应用;其次,对现有的机器学习模型进行了评估和分析;最后,本文认为虽然现有的基于机器学习的心血管疾病诊断方法已经可以媲美专业医生的水平,但是,该方法仍面临医学数据难以大量采集、医学成像信噪比低等困难。未来的研究方向应在小样本诊断模型的性能、多模态医学数据的融合、医学数据的共享等方面继续改进。

关键词 机器学习;心血管疾病;医学影像;多模态数据;辅助诊断

DOI:10.3969/j.issn.1002-3208.2020.02.015.

中图分类号 R318 **文献标志码** A **文章编号** 1002-3208(2020)02-0208-07

本文著录格式 赵梦蝶,孙九爱.机器学习在心血管疾病诊断中的研究进展[J].北京生物医学工程,2020,39(2):208-214. ZHAO Mengdie, SUN Jiulai. Review on machine learning approaches for cardiovascular disease diagnosis[J]. Beijing Biomedical Engineering, 2020, 39(2): 208-214.

Review on machine learning approaches for cardiovascular disease diagnosis

ZHAO Mengdie¹, SUN Jiulai²

- 1 School of Medical Instrument and Food Engineering, University of Shanghai for Science and Technology, Shanghai 200093;
- 2 Shanghai University of Medicine & Health Sciences, Shanghai 201318
Corresponding author: SUN Jiulai (E-mail: sunja@sumhs.edu.cn)

【Abstract】 At present, the diagnosis of cardiovascular diseases mainly depends on the analysis of cardiovascular images. Meanwhile, doctors also need to take into account the health indicators, medical history, living environment and other information of patients. This method has the disadvantages of low efficiency and high cost, and therefore, machine learning method has been adapted to solve these problems. This paper, summarizes the applications of machine learning in coronary computed tomography, echocardiography, electrocardiogram and so on. By evaluating and analyzing the existing models, the existing machine learning based methods may achieve similar level as clinical doctors. However the machine learning approaches need to solve the problems such as less training data and low signal-to-noise ratio of medical imaging data. The future research direction should continue to improve the performance of small sample diagnostic model, the fusion of multimodal medical data, the sharing of medical diagnostic data and so on.

【Keywords】 machine learning; cardiovascular disease; medical imaging; multimodal data; assistant diagnosis

基金项目:上海健康医学院协调创新专项(SPCI-17-18-001)资助

作者单位:1 上海理工大学医疗器械与食品学院(上海 200093)

2 上海健康医学院(上海 201318)

通信作者:孙九爱,博士,副教授。E-mail: sunja@sumhs.edu.cn

0 引言

心血管疾病是由环境、生活习惯、遗传基因等多种因素引起的人体心脏或血管系统的一系列疾病的总称,通常包括脑血管病、冠心病、心律失常、心力衰竭、肺血管病等。目前,心血管病死亡率居首位,高于肿瘤及其他疾病。据调查显示,我国心血管疾病的患病率及死亡率仍处于上升阶段,因此,防治心血管疾病刻不容缓^[1]。如图1所示,传统的心血管疾病诊断主要依赖经验丰富的放射科医师对医学影像进行人工阅片,同时结合考虑患者的生活环境、家族病史、生理指标等因素。这种方法容易受到医生一些主观因素和诊断方式的影响,并且,不同医师之间的诊断结果会不一致,存在一定程度的误诊和漏诊,目前中国基层医疗的人工诊断误诊率>50%^[2]。

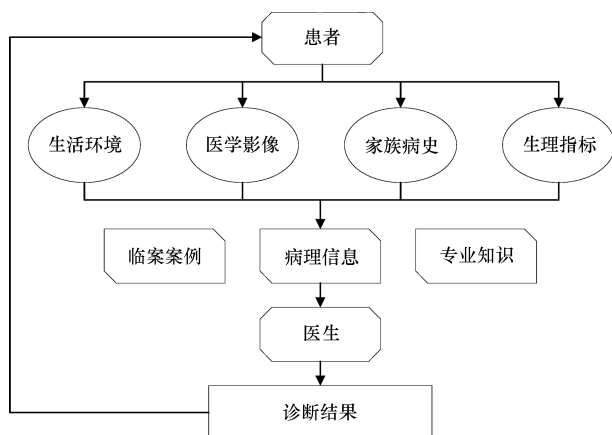


图1 传统的心血管疾病诊断方法流程图

Figure 1 Flowchart of traditional diagnosis of cardiovascular disease

机器学习是人工智能领域的重要分支之一,通过对数据的特征提取来自动学习数据的内在模式,使模型不断改善自身性能。机器学习模型的训练过程主要包括特征提取、数据预处理、模型优化等步骤,常见的模型包括人工神经网络(artificial neural network, ANN)、支持向量机(support vector machine, SVM)、K-最近邻(K-nearest neighbor, KNN)、随机森林(random forest, RF)、决策树(decision tree, DT)等。目前机器学习已经被广泛应用于医学图像处理领域,如图像分割^[3]、图像配准^[4]、图像识别^[5]和图像分类^[6]等。因此,通过医学大数据和机器学习技术进行辅助诊断已经成为现代医学发展的方向之

一。近年来,机器学习在基于医学影像数据的心血管疾病辅助诊断领域显得尤为突出。如图2所示,机器学习为传统的诊疗模式提供了新的思路,用于提高诊断效率,并且可以为患者进行更加客观和人性化的评估。在此基础上,本文详细总结了机器学习方法在心血管疾病诊断中的应用。

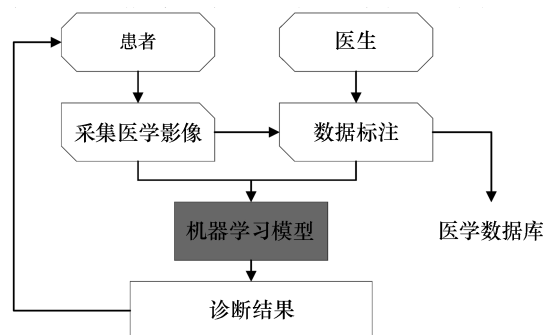


图2 基于机器学习的心血管疾病诊断方法流程

Figure 2 Flowchart of cardiovascular disease diagnosis based on machine learning

1 机器学习在心血管疾病诊断中的应用

目前基于机器学习的心血管疾病诊断方法主要是在特定的数据集上进行训练,得到诊断模型后完成新数据集上的特定诊断任务。本文按照不同的心血管成像形式,分别介绍了机器学习在心血管疾病诊断中的应用,具体研究成果见表1。

1.1 基于冠状动脉计算机断层扫描的机器学习辅助诊断应用

冠状动脉钙化是衡量冠心病严重程度的重要指标之一,冠状动脉计算机断层扫描血管造影(coronary computed tomography angiography, CCTA)是一种广泛用于冠心病检测和临床决策的无创心脏冠脉成像技术,用于诊断和排除阻塞性冠状动脉疾病,如冠状动脉狭窄检测、冠状动脉粥样硬化程度评估等。但是这些技术在临床上尚存在着成本效益和精度方面的局限性,机器学习的引入可以对其进行有效的补充。

Takx等^[7]使用KNN算法和SVM分类器对1793例低剂量胸部CT扫描图像进行自动检测并对冠状动脉钙化进行评分,实验结果表明这种方法所生成的评分与医生人工得出的评分相比,具有较强的一致性和可靠性。Isgum等^[8]同样使用机器学习

表 1 机器学习在心血管疾病诊断中的应用
Table 1 Application of machine learning in
diagnosing cardiovascular diseases

类别	研究时间	应用	例数
CT 检查	2014 ^[7]	冠状动脉钙化评估	1 793
	2018 ^[8]	全自动冠状动脉钙化评分	133
	2016 ^[9]	冠状动脉疾病诊断	10 030
	2018 ^[10]	冠心病的分级预测	185
	2018 ^[11]	冠心病的分级预测	6 814
	2018 ^[12]	胸腔扫描图分割	250
	2018 ^[13]	左心室心肌部分分割	166
超声心动图	2017 ^[14]	心尖超声视图分类	309
	2015 ^[15]	心内膜边界射血分数预测	255
	2016 ^[16]	左心室内膜分割	未统计
心电图	2005 ^[17]	心电图心率分类	11 343
	2018 ^[18]	心律失常分类	47
	2019 ^[19]	心电图心率分类	53 549
单光子发射 断层扫描	2017 ^[20]	二尖瓣平面定位	392
	2018 ^[21]	心肌灌注疾病预测	1 638
正电子发射 断层扫描	2015 ^[22]	冠脉斑块特征与受损心肌 血流储备对冠状血管功能 的影响	51
核磁共振	2017 ^[23]	心内外膜的全自动分割	256
血管内超声	2018 ^[24]	冠脉斑块识别	61
光学相干 断层扫描	2017 ^[25]	自动分类冠状动脉层	26

算法对 133 例低剂量 CT 衰减校正 (computed tomography attenuation correction, CTAC) 心肌灌注患者的影像 (85 位男性, 48 位女性, 平均年龄 69 岁) 进行自动钙化评分, 取得了与人工评分相近的结果, 且自动钙化评分的方法可以避免额外的辐射剂量和扫描时间。Motwani 等^[9]对 10 030 例疑似冠状动脉疾病患者连续跟踪 5 年, 所有患者均接受 CCTA 治疗。作者评估了 25 个临床参数和 44 个 CCTA 参数, 包括节段狭窄评分、节段介入评分、改良杜克指数、未钙化斑块节段数、混合钙化斑块节段数、钙化斑块节段数、年龄、性别、标准心血管危险因素和弗雷明汉危险评分等参数, 使用信息增益排序方法进行特征选择, 并使用十折交叉验证 (10-fold cross validation) 进行训练, 实验结果表明, 在预测全

因死亡率方面, 机器学习取得了更高的曲线下面积 (area under the curve, AUC)。

此外, 机器学习在冠心病的分级预测中也取得了不错的进展。Liu 等^[10]通过对 185 位中度冠心病患者进行为期 90d 的随访, 使用 5 种机器学习算法分别预测 90d 内可能会发生的心血管疾病事件 (全因死亡、心肌梗死、血运重建术、对比剂诱导的急性肾损伤和肾替代疗法) 的可能性, 其准确率可以媲美当前的基于非侵入性心脏成像的方法, 在进一步的研究中可以为计算机辅助诊断 (computer aided diagnosis, CAD) 和临床决策提供一种经济有效的工具。Nakanishi 等^[11]采用相同的方法对 6 814 名疑似冠心病患者进行随访, 实验结果表明机器学习算法相比较临床方法有更高的 AUC 值。

随着高性能计算模块的发展, 研究人员开始使用深度学习的方法对心脏 CT 图像进行端到端全自动分割, Commandeur 等^[12]通过使用卷积神经网络 (convolutional neural network, CNN) 对 250 张胸腔 CT 图和心外膜脂肪组织 CT 图进行分割, 全自动分割模型对胸腔和心外膜脂肪组织的分割结果与心脏病专家手动分割结果的相关性分别达到 0.945 和 0.926。结果表明基于深度学习算法的分割与临床专家的分割结果非常接近, 且分割时间仅需要 3 s。Zreik 等^[13]将深度神经网络 (deep neural network, DNN) 引入 CAD 的预测中, 实验数据来自 2012—2016 年采集的 166 例 CCTA 扫描数据。首先使用 CNN 将 CCTA 图像的左心室心肌部分进行分割, 然后通过自动编码器算法对其进行编码, 并将编码统计数据提取为分类特征, 使用 10 倍交叉验证且选取最佳 SVM 参数进行分类, 其结果显示平均 AUC 达到 0.75。

综上所述, 基于 CCTA 的诊断方法主要是使用 CNN 或者 DNN 对原始的扫描数据进行特征选择, 然后根据目标任务对特征进行分类、检测或者分割, 通常这种方法都是端到端的训练模型, 尽可能减少人工参与, 通过大数据对模型进行优化, 最终得到一个自动诊断系统, 该系统对于医生的辅助诊断是非常有效的, 大大降低人为操作存在的误诊问题。

1.2 基于超声心动图的机器学习辅助诊断应用

超声诊断 (ultrasonic diagnosis, USD) 是利用超声的特殊物理学特性检查心脏和大血管的解剖结构及功能状态的一种无创性技术。放射科医师在对

2D 超声心动图 (ultrasonic cardiogram, UCG) 进行阅片分析时,通常凭借自身经验进行估计判断,容易造成误诊和漏诊。为了提高效率和减少误诊率和漏诊率,相关的医疗企业已经开发了用于 2D 超声心动图分析的商业软件,例如通用电气医疗集团的 EchoPAC、飞利浦公司的 QLAB 等。虽然这些软件可以完成对待检测样本的分割与解剖,以及血液跟踪,但是仍然需要医生手动选择所需的图像进行分析和诊断。因此对大型数据库进行分类且精确识别视图是一件具有挑战性且耗费精力的工作。Khamis 等^[14]提出了一种全自动的心尖 UCG 视图分类法,使用 309 张临床 UCG 片段的心尖视图进行训练,该算法由空间特征提取和监督型字典学习方法组成,UCG 视图的识别和分类最终取得了平均 95% 的准确率。Knackstedt 等^[15]对 255 名窦性心率患者进行视觉估计和手动追踪评估心内膜边界射血分数,并且使用机器学习的软件 (AutoLV, TomTec-Arena 1.2, TomTec Imaging Systems, 德国) 用于全自动射血分数和平均双翼纵向应变的测量。将自动测量的值与通过视觉估计和手动追踪的值进行比较,实验结果表明使用机器学习软件的测量的准确率为 98%,且平均分析时间仅为 (8 ± 1) s/人。除此之外, Dong 等^[16]将深度学习应用在 2014 年 CETUS 挑战赛的 3D 超声心动图数据中,进行 3D UCG 的左心室心内膜的分割。与专家相比,该方法的结果有更高的准确性和诊断效率。

综上所述,UCG 视图的训练可以很好地进行辅助诊断,不仅可以帮助医生进行准确率的评估,还可以通过端到端的方式对数据进行 2D 和 3D 分割,这些结果可以媲美医生的分割结果^[16]。

1.3 基于心电图的机器学习辅助诊断应用

心律失常是心血管疾病中重要的一组疾病,是由于窦房结激动异常,或激动产生于窦房结以外,激动的传导缓慢、阻塞或经异常通道传导。心律失常可单独发病,也可与其他心血管疾病(如冠心病)伴发。心电图 (electrocardiogram, ECG) 是目前临床上对心律失常诊断的常规方法, ECG 由一组一维时间序列信号组成,但由于需要人工检查和二次解释,同时时间序列信号的信噪比低,容易造成医生的诊断偏差,因此在临床应用上具有一定的局限性。研究发现使用机器学习的方法可以有效提高诊断准确率和降低分析成本。机器学习模型如 ANN 和 SVM 可

以有效识别不同的波形 (QRS 波群、P 波和 T 波), 计算临床上重要的参数,例如心率、轴偏差和间隔长度,以及对 ST 段的检测,如心房颤动和室间传导延迟。2005 年, Zhao 等^[17]使用 11 343 例 ECG 信号数据通过使用小波变换提取变换系数作为每个心电图的特征,同时应用自回归建模来获得心电图波形的时间结构,最后使用高斯核的 SVM 对不同的心律进行分类,该方法最终精度达到 99.68%。2018 年, Scirè 等^[18]设计一种端到端的检测系统,用于可穿戴设备中处理和分析心电传感数据,自动检测心跳,并结合有监督机器学习算法对 47 名患者的心律失常进行分类。在心率失常分类结果中,该系统可以达到 96.8% 的准确率、89.1% 的召回率、80.5% 的精度和 84.4% 的 F1 分数。

除传统的机器学习算法外,深度学习也已经开始应用于心律失常的检测和分类。斯坦福大学机器学习小组^[19]使用 34 层 CNN 来检测各种心律失常,并发现与委员会认证的心脏病诊断专家相比,取得了 0.97 的 AUC 值,且在敏感性上超过了心脏病专家 (分别为 0.83 和 0.78) 的平均表现。由此证明使用机器学习算法,可以帮助临床医生大幅缩短分析 ECG 图的时间,提高工作效率。

综上所述, ECG 信号的处理通常分为两种方法,第一种是使用传统机器学习算法如 SVM 对一维的波形进行识别和分类;第二种方法是使用深度学习模型将一维数据转换为高维数据,并对其进行特征的提取和分类。两种方法均优于临床医生的表现,具有实际的临床应用价值。

1.4 基于单光子发射计算机断层扫描和正电子发射断层扫描的机器学习辅助诊断应用

单光子发射计算机断层扫描 (single-photon emission computed tomography, SPECT) 测试进行心肌灌注 (myocardial perfusion imaging, MPI) 的评估,与冠状动脉阻塞有着直接的关系,在使用 SPECT 扫描 MPI 过程中需要手动定义二尖瓣平面。2017 年 Betancur 等^[20]使用 SVM 方法来自动定位二尖瓣平面,这对于 MPI 的准确评估起到非常重要的作用。他们对 392 例患者的 SPECT 扫描结果进行训练与验证,最终测试结果表明,在衰减校正和非衰减校正图像处理结果中, SVM 算法均取得了和专业医生非常接近的 AUC 值 (非衰减校正: SVM 的值为 0.79, 医生 1 和医生 2 分别为 0.8 和 0.77; 衰减校正: SVM

的值为 0.82, 医生 1 和医生 2 分别为 0.81 和 0.79)。2018 年, Betancur 等^[21]采用深度学习方法, 对 1 638 名患者进行 MPI 阻塞性疾病的自动预测和评估, 结果证明深度学习方法的准确率高于临床专家手动定位的准确率。Dey 等^[22]对 51 位患者通过正电子发射断层扫描(positron emission tomography, PET)研究冠状动脉计算机扫描血管造影和冠状动脉血管功能障碍的定量斑块特征与心肌血流储备受损之间的关系, 机器学习算法结果显示其风险评分 AUC 为 0.83, 对于定量狭窄的 AUC 为 0.66。

1.5 机器学习辅助诊断在其他成像方式中的应用

机器学习算法不仅运用在上述心血管成像模式中, 同时在磁共振成像(magnetic resonance imaging, MRI)、血管内超声(intravascular ultrasound, IVUS)和光学相干断层扫描(optical coherence tomography, OCT)中都有所应用。Dawes 等^[23]采用机器学习的方法, 通过有监督的心脏收缩运动的三维模式对 256 例患者的 MRI 图像进行肺动脉高压预测分析, 其结果显示深度学习的 AUC 值达到 0.73。Zhang 等^[24]对 61 例患者的血管内超声图像进行机器学习训练, 用于识别易于发生严重不良心脏事件的高风险冠状动脉斑块。结果显示, 该机器学习方法预测纤维化动脉瘤和非纤维化动脉瘤的准确率分别为 85.9% 和 81.7%。该实验证明了通过使用局灶性血管特征和人口统计学变量的机器学习方法, 对未来高危冠状动脉斑块的位置特异性的检测是可行的。Abdolmanafi 等^[25]将深度学习运用在 26 例川崎病患者的 OCT 图像中, 主要进行冠状动脉层的自动分类。川崎病是一种急性儿童疾病, 主要表现为冠状动脉瘤、内膜增厚、血栓、狭窄、板层钙化和介质边界消失。因此, 冠状动脉层的自动分类对于分析患者的 OCT 扫描图像至关重要。该算法先通过深度 CNN 作为特征提取器, 然后比较基于 CNN、RF 和 SVM 三种分类器的准确率。实验结果表明, 其中使用 CNN 作为特征提取器和 RF 作为分类器的效果最佳, 此模型得到的准确率为 0.92, 敏感性和特异性分别为 0.85 和 0.99。

2 机器学习在心血管疾病辅助诊断中尚需解决的问题

表 2 从 6 个角度分别对比了人工阅片诊断和机器学习诊断之间的区别。由此可知, 机器学习在心

血管疾病诊断中具有快速、准确、高效率等优点, 可以帮助医生节省阅片时间, 进一步提高对患者的诊断效率, 为患者提供更加具有针对性的治疗方案。

表 2 人工阅片诊断与机器学习诊断模式的对比
Table 2 Comparison of diagnostic models of manual reading and machine learning

对比指标	人工阅片诊断	机器学习诊断
阅片时间	与医生的专业程度相关, 一般都需要几分钟到几小时	在极短时间内即可完成大量阅片
诊断依据	依据医生的个人经验和计算机辅助诊断	依据大量的同类病人信息和机器预测模型
准确率	存在主观偏差, 与医生的专业训练程度和个人经验相关	借助医疗大数据可以实现媲美甚至超越临床医师的诊断水平
差异性	较大	较小
诊断效率	由于人工阅片的主观性和疲劳程度, 效率往往较低	机器学习模型可以同时处理巨量数据, 阅片效率较高
样本重复利用率	与医师的记忆力和医院的病人数据库完备程度有关	病人信息不断加入模型训练中, 提高模型的准确率

机器学习方法的引入可以辅助实现临床快速诊断, 特别是最新的深度学习已在医学应用中取得了很大的研究进展^[26], 但对于心血管疾病的准确诊断和早期预测, 无论是在临床上, 还是在机器学习方法中都还是一个尚未完全解决的问题。为了将机器学习方法全面运用到心血管疾病的日常临床影像分析和诊断应用中, 至少还需解决如下问题。

(1) 小样本问题。传统机器学习算法在很多领域都取得了很好的进展, 这得益于大量训练样本。但对医学数据而言, 尤其是在心血管疾病领域, 研究人员往往无法大规模采集数据, 这是因为存在社会伦理、隐私、安全等问题, 且不同医院的样本库之间一般无法共享使用, 导致无法获得足够规模的样本进行训练。而样本小必然会导致过拟合, 一般的数据增量法并不能增加样本的特征多样性, 不会对过拟合有本质的改善^[27]。

(2) 数据标注问题。医学数据的标注需要专业医生来进行, 以此来保证训练数据的可靠性。但是由于人的主观性差异, 一个数据库通常由多位医生重复标注和检测, 导致标注成本高且耗时较长。

(3) 样本平衡性问题。对于医学数据, 通常无

法提前预知正负样本的数量,如肿瘤良恶性的患者数量等,所以很多数据集都是非平衡样本,即正负样本的数量差异较大,最终导致敏感性和特异性的差距较大,即模型的鲁棒性较差^[27-28]。

(4) 信噪比低的问题。由于心血管的形态结构尺寸有限,组织之间的差异性较小,目前的断层扫描层间分辨率有时不能完全捕捉到病灶,造成后续分割任务难度增大,降低诊断效率和精度^[29-30]。

(5) 模型的普适性低的问题。当前的算法往往都是在特定的数据集上进行训练,缺乏其他数据集的检验,导致模型的普适性较差,在某一数据集上的结果较好,但是换一个数据集后就无法取得理想的性能。

3 小结与展望

本文首先说明了机器学习方法在心血管疾病辅助诊断中的必要性,接着从医学成像技术的角度,介绍了机器学习方法在5种不同成像模式中的应用,说明了机器学习在心血管疾病诊断领域中已经取得了可以媲美医生的水平,可以很大程度地帮助医生提高诊断效率。最后总结了机器学习方法的优势,并对现有方法的不足和限制进行了分析,如训练数据样本小问题、样本不平衡、数据信噪比低、模型的适应性差等。

针对现有的基于机器学习方法的心血管疾病诊断模型的优缺点,下列可能会成为未来的研究方向。

(1) 建立更加完备的心血管疾病云数据库,加强医学数据的共享。

(2) 研究小样本医学数据处理的模型优化和过拟合的解决方法,从算法上解决样本小的问题,如元学习等模型。

(3) 研究多模态医学数据的融合算法,如将PET数据的特征融入到MRI数据中,增加原始特征的多样性,如特权信息学习(learn using privilege information)等模型。

参考文献

- [1] 胡盛寿,高润霖,刘力生,等.《中国心血管病报告2018》概要[J]. 中国循环杂志,2019,34(3):209-220.
Hu SS, Gao RL, Liu LS, et al. Summary of the 2018 Report on Cardiovascular Diseases in China [J]. Chinese Circulation Journal, 2019, 34(3): 209-220.

- [2] 中国医学影像AI产学研用创新联盟. 中国医学影像AI白皮书[EB/OL]. [2019-03-26] <https://vcbeat.top/Njk3NjZINWIkZTNjMDJkZjZlMDgOM2YzZjY3YTlkZjc=>
- [3] Wang G, Li W, Zuluaga MA, et al. Interactive medical image segmentation using deep learning with image-specific fine tuning [J]. IEEE Transactions on Medical Imaging, 2018, 37(7): 1562-1573.
- [4] Balakrishnan G, Zhao A, Sabuncu MR, et al. An unsupervised learning model for deformable medical image registration [C]// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle, Washington, USA: IEEE Press, 2018: 9252-9260.
- [5] Hu L, Cui J. Digital image recognition based on fractional-order-PCA-SVM coupling algorithm [J]. Measurement, 2019, 145: 150-159.
- [6] Frid-Adar M, Diamant I, Klang E, et al. GAN-based synthetic medical image augmentation for increased CNN performance in liver lesion classification [J]. Neurocomputing, 2018, 321: 321-331.
- [7] Takx RAP, de Jong PA, Leiner T, et al. Automated coronary artery calcification scoring in non-gated chest CT: agreement and reliability [J]. PLoS One, 2014, 9(3): e91239.
- [8] Išgum I, de Vos B, Wolterink J, et al. Automatic determination of cardiovascular risk by CT attenuation correction maps in Rb-82 PET/CT [J]. Journal of Nuclear Cardiology, 2018, 25(6): 2133-2142.
- [9] Motwani M, Dey D, Berman D, et al. Machine learning for prediction of all-cause mortality in patients with suspected coronary artery disease: a 5-year multicentre prospective registry analysis [J]. European Heart Journal, 2016, 38(7): 500-507.
- [10] Liu Y, Dai X, Wolf H, et al. A machine-learning model in predicting hemodynamically significant coronary artery disease: a prospective cohort study [J]. Circulation, 2018, 138(Suppl_1): A10602.
- [11] Nakanishi R, Dey D, Commandeur F, et al. Machine learning in predicting coronary heart disease and cardiovascular disease events: results from the multi-ethnic study of atherosclerosis (MESA) [J]. Journal of the American College of Cardiology, 2018, 71(11 Supplement): A1483.
- [12] Commandeur F, Goeller M, Betancur J, et al. Deep learning for quantification of epicardial and thoracic adipose tissue from non-contrast CT [J]. IEEE Transactions on Medical Imaging, 2018, 37(8): 1835-1846.
- [13] Zreik M, Lessmann N, van Hamersvelt RW, et al. Deep learning analysis of the myocardium in coronary CT angiography for identification of patients with functionally significant coronary

- artery stenosis[J]. Medical image analysis, 2018, 44: 72–85.
- [14] Khamis H, Zurakhov G, Azar V, et al. Automatic apical view classification of echocardiograms using a discriminative learning dictionary[J]. Medical Image Analysis, 2017, 36: 15–21.
- [15] Knackstedt C, Bekkers SC, Schummers G, et al. Fully automated versus standard tracking of left ventricular ejection fraction and longitudinal strain: the FAST-EFs Multicenter Study[J]. Journal of the American College of Cardiology, 2015, 66 (13): 1456–1466.
- [16] Dong S, Luo G, Sun G, et al. A left ventricular segmentation method on 3D echocardiography using deep learning and snake [C]// 2016 Computing in Cardiology Conference. Vancouver, BC, Canada: IEEE Press, 2016, 43: 473–476.
- [17] Zhao Q, Zhang L. ECG feature extraction and classification using wavelet transform and support vector machines [C]// 2005 International Conference on Neural Networks and Brain. Beijing, China: IEEE Press, 2005, 2: 1089–1092.
- [18] Scirè A, Chatzigiannakis I, Anagnostopoulos A. Heartbeat detection and arrhythmia classification from the ECG signal using machine learning techniques [D]. Rome: University of Rome, 2018.
- [19] Hannun AY, Rajpurkar P, Haghpanahi M, et al. Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network [J]. Nature Medicine, 2019, 25(1): 65–69.
- [20] Betancur J, Rubeaux M, Fuchs T, et al. Automatic valve plane localization in myocardial perfusion SPECT/CT by machine learning: anatomic and clinical validation[J]. Journal of Nuclear Medicine, 2017, 58(6): 961–967.
- [21] Betancur J, Commandeur F, Motlagh M, et al. Deep learning for prediction of obstructive disease from fast myocardial perfusion SPECT: a multicenter study[J]. JACC: Cardiovascular Imaging, 2018, 11(11): 1654–1663.
- [22] Dey D, Diaz Zamudio M, Schuhbaeck A, et al. Relationship between quantitative adverse plaque features from coronary computed tomography angiography and downstream impaired myocardial flow reserve by ^{13}N -ammonia positron emission tomography: a pilot study [J]. Circulation: Cardiovascular Imaging, 2015, 8(10): e003255.
- [23] Dawes T, de Marvao A, Shi W, et al. Machine learning of three-dimensional right ventricular motion enables outcome prediction in pulmonary hypertension: a cardiac MR imaging study [J]. Radiology, 2017, 283(2): 381–390.
- [24] Zhang L, Wahle A, Chen Z, et al. Predicting locations of high-risk plaques in coronary arteries in patients receiving statin therapy [J]. IEEE Transactions on Medical Imaging, 2018, 37 (1): 151–161.
- [25] Abdolmanafi A, Duong L, Dahdah N, et al. Deep feature learning for automatic tissue classification of coronary artery using optical coherence tomography [J]. Biomedical Optics Express, 2017, 8 (2): 1203–1220.
- [26] Shen D, Wu G, Suk HI. Deep learning in medical image analysis [J]. Annual Review of Biomedical Engineering, 2017, 19: 221–248.
- [27] 孙凯. 随机森林在医学影像分析中的应用研究进展[J]. 北京生物医学工程, 2018, 37(4): 413–418.
- Sun K. Research progress on application of random forest in medical image analysis [J]. Beijing Biomedical Engineering, 2018, 37(4): 413–418.
- [28] 袁丽, 吴水才, 袁延超. 一种改进的 FastICA 算法在胎儿心电图提取中的应用 [J]. 北京生物医学工程, 2018, 37 (5): 488–493.
- Yuan L, Wu SC, Yuan YC. Application of an improved FastICA algorithm in fetal electrocardiogram extraction [J]. Beijing Biomedical Engineering, 2018, 37(5): 488–493.
- [29] 翟柏松, 赵向蕊, 陈向前, 等. 术中透视图像质量对双平面定位算法精度的影响 [J]. 北京生物医学工程, 2017, 36 (4): 372–377.
- Zhai BS, Zhao XR, Chen XQ, et al. Influence of intraoperative fluoroscopy images' quality on the accuracy of bi-planar positioning method [J]. Beijing Biomedical Engineering, 2017, 36 (4): 372–377.
- [30] 伍建林, 鄂亚军, 张清, 等. 嗅觉脑功能磁共振成像中提高敏感性脑区信噪比的参数优化研究 [J]. 中国医学影像技术, 2007, 23(12): 1764–1768.
- Wu JL, E YJ, Zhang Q, et al. Study of parameter optimum on the olfaction fMRI for increasing SNR of the susceptibility regions of human brain [J]. Chinese Journal of Medical Imaging Technology, 2007, 23(12): 1764–1768.

(2019-08-23 收稿, 2019-11-22 修回)